统计中的计算方法 第二次作业

于慧倩 14300180118 2017 年 4 月

- 1. 已知隐马尔科夫链的状态转移概率如图一所示, 对输出状态 A,B 的输出概率为 e1(A) = 0.5, e1(B) = 0.5, e2 (A) = 0.1, e2 (B) = 0.9, e3 (A) = 0.9, e3 (B) = 0.1。完成 1-5 题:
 - (a) 用向前方法计算出现状态 BAB 的概率。

$$P(BAB) = 0.1 \times f_1(3) + 0.2 \times f_2(3) + 0.4 \times f_3(3)$$

用 forward 方法求解 $f_1(3), f_2(3), f_3(3)$:

$$f_1(1) = 0.2 \times 0.5 = 0.1$$

$$f_2(1) = 0.3 \times 0.9 = 0.27$$

$$f_3(1) = 0.5 \times 0.1 = 0.05$$

$$f_1(2) = 0.5 \times (0.3 \times 0.1 + 0) = 0.015$$

$$f_2(2) = 0.1 \times (0.3 \times 0.1 + 0.4 \times 0.27 + 0.3 \times 0.05) = 0.0153$$

$$f_3(2) = 0.9 \times (0.3 \times 0.1 + 0.4 \times 0.27 + 0.3 \times 0.05) = 0.1377$$

$$f_1(3) = 0.5 \times (0.3 \times 0.015) = 0.00225$$

$$f_2(3) = 0.9 \times (0.3 \times 0.015 + 0.4 \times 0.0153 + 0.3 \times 0.1377) = 0.046737$$

$$f_3(3) = 0.1 \times (0.3 \times 0.015 + 0.4 \times 0.0153 + 0.3 \times 0.1377) = 0.005193$$

故

$$P(BAB) = 0.1 \times f_1(3) + 0.2 \times f_2(3) + 0.4 \times f_3(3) = 0.0116496$$

(b) 用向后方法计算出现状态 BAB 的概率。

$$P(BAB) = 0.2 \times 0.5 \times b_1(1) + 0.3 \times 0.9 \times b_2(1) + 0.5 \times 0.1 \times b_3(1)$$

用 backward 方法求解 $b_1(1), b_2(1), b_3(1)$:

$$b_1(3) = 0.1, b_2(3) = 0.2, b_3(3) = 0.4$$

$$b_1(2) = 0.3 \times 0.5 \times 0.1 + 0.3 \times 0.9 \times 0.2 + 0.3 \times 0.1 \times 0.4 = 0.081$$

$$b_2(2) = 0.4 \times 0.9 \times 0.2 + 0.4 \times 0.1 \times 0.4 = 0.088$$

$$b_3(2) = 0.3 \times 0.9 \times 0.2 + 0.3 \times 0.1 \times 0.4 = 0.066$$

$$b_1(1) = 0.3 \times 0.5 \times 0.081 + 0.3 \times 0.1 \times 0.088 + 0.3 \times 0.9 \times 0.066 = 0.03261$$

$$b_2(1) = 0.4 \times 0.1 \times 0.088 + 0.4 \times 0.9 \times 0.066 = 0.02728$$

$$b_3(1) = 0.3 \times 0.1 \times 0.088 + 0.3 \times 0.9 \times 0.066 = 0.02046$$

故

$$P(BAB) = 0.2 \times 0.5 \times b_1(1) + 0.3 \times 0.9 \times b_2(1) + 0.5 \times 0.1 \times b_3(1) = 0.0116496$$

(c) 对 BAB 计算对每个显示状态, 隐状态 G₂ 的概率。

$$\begin{split} P(s_1 = G_2 | x_1 = B) &= \frac{P(s_1 = G_2, x_1 = B)}{P(x_1 = B)} \\ &= \frac{P(x_1 = B | s_1 = G_2) P(s_1 = G_2)}{\sum_{l=1,2,3} P(x_1 = B | s_1 = G_l) P(s_1 = G_l)} \\ &= \frac{0.9 \times 0.3}{0.5 \times 0.2 + 0.9 \times 0.3 + 0.1 \times 0.5} \\ &= 0.6428571 \end{split}$$

$$\begin{split} P(s_2 = G_2 | x_2 = A) &= \frac{P(s_2 = G_2, x_2 = A)}{P(x_2 = A)} \\ &= \frac{P(x_2 = A | s_2 = G_2) P(s_2 = G_2)}{\sum_{l=1,2,3} P(x_2 = A | s_2 = G_l) P(s_2 = G_l)} \\ &= 0.09166667 \end{split}$$

$$\begin{split} P(s_3 = G_2 | x_3 = B) &= \frac{P(s_3 = G_2, x_3 = B)}{P(x_3 = B)} \\ &= \frac{P(x_3 = B | s_3 = G_2) P(s_3 = G_2)}{\sum_{l=1,2,3} P(x_3 = B | s_3 = G_l) P(s_3 = G_l)} \\ &= 0.8686047 \end{split}$$

- (d) 对 BAB 计算隐状态为 $G_1G_2G_1$ 的概率。 由于从 G_2 转移到 G_1 的概率为 0,所以隐状态为 $G_1G_2G_1$ 的概率为 0.
- (e) 对 BAB 计算最优的隐状态路径。

$$\begin{split} v_1(1) &= 0.5 \times 0.2 = 0.1, v_2(1) = 0.9 \times 0.3 = 0.27, v_3(1) = 0.1 \times 0.5 = 0.05 \\ v_1(2) &= 0.5 \times \max\{0.1 \times 0.3, 0, 0\} = 0.015 \\ v_2(2) &= 0.1 \times \max\{0.3 \times 0.1, 0.4 \times 0.27, 0.3 \times 0.05\} = 0.108 \\ v_3(2) &= 0.9 \times \max\{0.3 \times 0.1, 0.4 \times 0.27, 0.3 \times 0.05\} = 0.972 \\ v_1(3) &= 0.5 \times \max\{0.3 \times 0.015, 0, 0\} = 0.00225 \\ v_2(3) &= 0.9 \times \max\{0.3 \times 0.015, 0.4 \times 0.108, 0.3 \times 0.972\} = 0.26244 \\ v_3(3) &= 0.1 \times \max\{0.2 \times 0.015, 0.4 \times 0.108, 0.3 \times 0.972\} = 0.02916 \end{split}$$

由此得到,最优隐状态路径为 G_2, G_3, G_2 ,这条隐状态概率为 0.26244

2. 假设 HMM 隐状态为 A,B, 显示状态为 L,R, 对附件数据 assign2.csv, 估计 HMM 的参数, 并估计出现此隐状态的概率。数据中包含 2 条链的隐状态和显示状态。

解:

(a) 推导过程

使用最大似然估计对隐状态已知的马尔可夫链进行参数估计: 设转移矩阵为 A,发射矩阵为 E,其中 a_{ij} 代表从 j 转移到 i 状态的概率, e_{ij} 代表从 j 发射出 i 状态的概率。设 AA $\tilde{A}A$ 分别为第一条链、第二条链的转移频数矩阵,EE \tilde{EE} 分别为第一条链、

第一条链、第二条链的转移频数矩阵, $EE\ \tilde{EE}\$ 分别为第一条链、第二条链的发射频数矩阵,(其中 $AA_{i,j}$ 代表第一条链中隐状态由 j 变为 i 的频数, $EE_{i,j}$ 代表第一条链中隐状态 j 发射出显状态 i

的频数)。

由于数据中包含两条链的隐状态和显状态,有利用最大似然估计:

$$\begin{split} Q(\theta|\theta^{(t)}) &= arg \text{max} L(\theta|\pmb{X}_1, \pmb{S}_1, \pmb{X}_2, \pmb{S}_2) \\ &= arg \text{max} \log P(\theta|\pmb{X}_1, \pmb{S}_1, \pmb{X}_2, \pmb{S}_2) \\ &= arg \text{max} \{\log P(\theta|\pmb{X}_1, \pmb{S}_1) + \log P(\theta|\pmb{X}_2, \pmb{S}_2)\} \\ &= arg \text{max} \log \prod_{k=1,2;l=1,2} (a_{k,l})^{AA_{k,l}} (a_{k,l})^{\tilde{A}\tilde{A}_{k,l}} (e_{k,l})^{\tilde{E}\tilde{E}_{k,l}} \\ &= arg \text{max} \{ \sum_{k=1,2;l=1,2} (AA_{k,l} + \tilde{A}\tilde{A}_{k,l}) \log a_{k,l} \\ &+ \sum_{k=1,2;l=1,2} (EE_{k,l} + \tilde{E}\tilde{E}_{k,l}) \log e_{k,l} \} \end{split}$$

令其对参数求导等于零,得到:

$$a_{k,l} = \frac{AA_{k,l} + \tilde{A}A_{k,l}}{AA_{k,l} + AA_{k',l} + \tilde{A}A_{k,l} + \tilde{A}A_{k',l}}$$

$$e_{k,l} = \frac{EE_{k,l} + \tilde{E}E_{k,l}}{AA_{k,l} + AA_{k',l} + \tilde{A}A_{k,l} + \tilde{A}A_{k',l}}$$

$$(k = 1, 2; l = 1, 2)$$

- (b) 编写程序 H2_2.R 计算,最终得到转移矩阵与发射矩阵:
 - i. 转移矩阵

$$\left(\begin{array}{cc} 0.854546 & 0.193182 \\ 0.145455 & 0.806818 \end{array}\right)$$

ii. 发射矩阵

$$\left(\begin{array}{cc} 0.6636364 & 0.2727273 \\ 0.3363636 & 0.7272727 \end{array}\right)$$

(c) 求该隐状态出现的概率, 即 $P(s_i = l | \mathbf{X})$ 出现的概率:

$$P(s_i = l | \mathbf{X}) = \frac{P(\mathbf{X}, s_i = l)}{P(\mathbf{X})}$$

$$= \frac{P(\mathbf{X}, s_i = l)}{\sum_k P(\mathbf{X}, s_i = l_k)}$$

$$= \frac{f_{s_i}(l)b_{s_i}(l)}{\sum_k f_{s_i}(l_k)b_{s_i}(l_k)}$$

由程序 $H2_2.R$ 得到该隐状态出现的概率如 $P_x_s.$

- 3. 同 (二), 对附件数据 assign3.csv, 估计 HMM 的参数, 并估计最优隐状态路径。数据中包含 2 条链的隐状态。
 - (a) 估计参数
 - i. 用向前方法计算:

$$f_l(i) = e_l(x_i) \sum_k f_k(i-1) \cdot a_{kl}; (i=2:L)$$

ii. 用向后方法计算:

$$B(s_i) = \sum_{s_{i+1}} P(s_{i+1}|s_i) P(x_{i+1}|s_{i+1}) B(s_{i+1}); (i = 1: L-2)$$

$$B(s_{L-1}) = P(x_L|s_{L-1}) = \sum_{s_L} P(s_L|s_{L-1})P(x_L|x_L)$$

iii. 有两条观察到的显链, 所以利用 EM 算法得到参数估计值:

A. E-step:

$$Q(\theta|\theta^{t}) = \sum_{j} \sum_{s^{j} \in S^{j}} P(s^{j}|X^{j}, t\theta^{t}) \log P(x^{j}, X^{j}|\theta)$$

$$= \sum_{j} \sum_{s^{j} \in S^{j}} P(s^{j}|X^{j}, t\theta^{t}) \log(\pi_{s_{1}}^{j} \prod_{t=1}^{T} a_{s_{t-1}s_{t}} e_{s_{t}}(x_{t}))$$

B. M-step:

初始发射概率:

$$\pi_{1,i} = \frac{1}{2} \sum_{j=1}^{2} P(S_1^j = i | X^j, \theta^t)$$

转移数量矩阵:

$$A_{kl} = \sum_{j=1}^{2} \frac{1}{P(X^{j})} \sum_{i=1}^{L} P(X^{j}, s_{i-1} = k, s_{i} = l)$$
$$= \sum_{j=1}^{2} \frac{1}{P(X^{j})} \sum_{i=1}^{L} f_{k}^{j} (i-1) a_{kl}^{j} e_{l}^{j} (x_{i}) b_{l}^{j} (i)$$

发射数量矩阵:

$$E_k(b) = \sum_{i=1}^{2} \frac{1}{P(X^j)} \sum_{i:x_i=b} f_k^j(i) b_k^j(i)$$

从而得到转移矩阵与发射矩阵的迭代公式:

$$a_{kl} = \frac{A_{kl}}{\sum_{l'} A_{kl'}}, e_k(b) = \frac{E_k(b)}{\sum_{l'} E_k(b')}$$

(b) 迭代结果

如程序 H2_3.R 最终得到转移矩阵与发射矩阵如下:

i. 转移矩阵

$$\left(\begin{array}{ccc} 0.8875018 & 0.04368625 \\ 0.1124982 & 0.9563138 \end{array}\right)$$

ii. 发射矩阵

$$\left(\begin{array}{cc} 0.8375897 & 0.3603209 \\ 0.1624103 & 0.6396791 \end{array}\right)$$

(c) 估计最优隐状态路径

估计出两条链的最优隐状态如下: